

Reporte Metodológico (Documentación Técnica) Este documento respalda la veracidad, integridad y metodología de los datos presentados.

1. Fuentes de Datos y Herramientas

- **Fuentes:** empleados_mensual.csv, capacitaciones.csv, eventos_rrhh.csv.
- **Herramientas:** Python (Librerías: Pandas para manipulación y ETL; Seaborn/Matplotlib para visualización estadística).
- **Entorno de Ejecución:** Google Colab (Jupyter Notebook en la nube).

2. Limpieza y Calidad del Dato (Data Wrangling) Para asegurar la fiabilidad del análisis, se realizaron las siguientes intervenciones:

- **Decodificación de Caracteres:** Se normalizaron errores de codificación Latin-1 (ej. "AdministraciÃ³n" → "Administración") mediante funciones recursivas de limpieza de texto.
- **Normalización de Formatos:** Estandarización de tipos de datos (fechas, numéricos, booleanos) en las tres bases de origen.
- **Corrección de Género:** Se detectaron y corrigieron 714 inconsistencias donde nombres masculinos figuraban con género femenino, utilizando un diccionario de validación basado en nombres de pila.
- **Lógica Temporal:** Se recalcularon edades, antigüedades y proyección de jubilación con fecha de corte al **2025-05-31** para asegurar precisión al día exacto.
- **Reclasificación de Capacitaciones:** Se corrigieron categorías mal etiquetadas en origen (ej. cursos técnicos marcados como "Gestión") mediante un mapeo semántico de palabras clave.

3. Validaciones y Auditoría de Datos Se aplicaron algoritmos de consistencia lógica entre las bases de RRHH y Operaciones:

- **Integridad Referencial:** Verificación de duplicados, valores nulos críticos y consistencia de IDs únicos.
- **Cruce Headcount vs. Capacitaciones:** Detección de empleados marcados como "Capacitados" en su ficha personal sin respaldo en el registro histórico de cursos.
- **Cruce Headcount vs. Eventos:** Auditoría mes a mes de ausentismo. Se hallaron discrepancias entre los días descontados en nómina y los días reportados operativamente, sugiriendo fugas de información.

4. Generación de Tablas Maestras (Outputs) Se generaron cuatro datasets limpios y normalizados para el análisis:

- **headcount_actual:** Snapshot con datos personales y métricas de la nómina activa actual.
- **headcount_acumulado:** Historial evolutivo mes a mes de cada empleado activo.
- **capacitaciones_actual:** Registro validado de entrenamientos del personal activo.

- **eventos_actual:** Registro histórico saneado de incidentes y ausencias.

5. Metodología de Análisis Específicos

- **Cálculo de ROI (Retorno de Inversión):** Comparación de tasas medias (Scrap, Unidades, Accidentes) entre cohortes de empleados "Capacitados" vs. "No Capacitados", aislando la población *Blue Collar* (Operarios) para eliminar sesgos.
- **Algoritmo de Sucesión:** Implementación de lógica de emparejamiento. Para cada posición crítica en edad de jubilación (>63 años), el sistema identificó reemplazos internos del mismo puesto con la mayor antigüedad acumulada.
- **Análisis de Equidad y Brecha Salarial:**
 - *Techo de Cristal:* Cálculo de % de participación femenina por nivel jerárquico.
 - *Brecha de Bonos:* Comparación de ingreso total vs. base entre géneros para aislar el impacto de los incentivos variables.
- **Estimación de Costos de Incidentes:**
 - *Directos:* Costos médicos y de reparación reportados.
 - *Indirectos:* Días perdidos valorizados al salario diario promedio del operario.

6. Suposiciones Clave

- Se asume que la base "Eventos" representa la totalidad de los accidentes ocurridos.
- Para la alerta temprana de jubilación, se estandarizó la edad de retiro en 65 años.

7. Código: Se adjunta el archivo *Assignment_TechnoStamp_Industries.ipynb* con los bloques de código completos.